

Análise da Detecção de Glaucoma Utilizando Modelos de Aprendizado de Máquina

Pedro Lucas Alves de Carvalho
Sistemas de Informação
Universidade Federal de Viçosa
Rio Paranaíba, Minas Gerais
pedro.l.carvalho@ufv.br

João Fernando Mari
Sistemas de Informação
Universidade Federal de Viçosa
Rio Paranaíba, Minas Gerais
joaof.mari@ufv.br

I. RESUMO

O glaucoma é uma das principais causas de cegueira irreversível no mundo, afetando cerca de 76 milhões de pessoas em 2020. Esse número deve crescer devido ao envelhecimento populacional e à dificuldade de acesso ao diagnóstico precoce, especialmente em regiões subdesenvolvidas. A doença, caracterizada por danos progressivos ao nervo óptico associados a altos níveis de pressão intraocular, exige intervenção precoce para evitar a perda de visão. Métodos tradicionais, como a gonioscopia, dependem de exames invasivos e da interpretação subjetiva de especialistas, limitando sua acessibilidade. Este estudo explora os avanços recentes em aprendizado de máquina (ML) e deep learning para automatizar a análise de imagens médicas, destacando métricas como perdas de treinamento, precisão e matrizes de confusão, e identificando estratégias para melhorias na detecção do glaucoma.

Abstract—Glaucoma is one of the leading causes of irreversible blindness worldwide, affecting approximately 76 million people in 2020. This number is expected to rise due to population aging and challenges in accessing early diagnosis, especially in underdeveloped regions. The disease, characterized by progressive damage to the optic nerve associated with high intraocular pressure levels, requires early intervention to prevent vision loss. Traditional methods, such as gonioscopy, rely on invasive procedures and subjective specialist interpretation, limiting accessibility. This study explores recent advancements in machine learning (ML) and deep learning for automating medical image analysis, focusing on metrics such as training losses, accuracy, and confusion matrices, and identifying strategies for improving glaucoma detection.

Index Terms—Aprendizado de Máquina, Detecção de Glaucoma, Imagens Médicas, Matriz de Confusão, Avaliação de Modelos.

II. INTRODUÇÃO

O glaucoma é uma das principais causas de cegueira irreversível no mundo, afetando milhões de pessoas a nível global. Estima-se que a doença seja responsável por até 12 por cento dos casos de cegueira irreversível, representando uma preocupação crescente para a saúde pública mundial.

O glaucoma é caracterizado pela degeneração progressiva do nervo óptico, frequentemente associada ao aumento da pressão intraocular (PIO), embora também possa ocorrer com níveis normais de pressão. Esse dano ao nervo óptico resulta em uma perda gradual do campo visual, que pode começar de forma sutil e assintomática, dificultando o diagnóstico precoce da doença. Nos estágios iniciais, a condição pode ser totalmente silenciosa, sem sinais evidentes, o que torna a detecção da doença um desafio significativo.

Estudos indicam que cerca de 50 por cento das pessoas com glaucoma desconhecem sua condição, o que aumenta ainda mais o risco de danos irreversíveis à visão. Esse panorama é particularmente preocupante em países em desenvolvimento, onde a falta de acesso a exames oftalmológicos adequados e a escassez de recursos limitam o diagnóstico precoce e o tratamento eficaz. Além disso, o risco de desenvolver glaucoma é exacerbado por diversos fatores, como o envelhecimento da população, histórico familiar de glaucoma, hipertensão ocular, diabetes, entre outros. A interação complexa entre esses fatores genéticos e ambientais sublinha a importância de uma abordagem personalizada no diagnóstico e no tratamento do glaucoma, e reforça a necessidade de métodos mais rápidos, acessíveis e eficientes para detectar a doença em suas fases iniciais.

Nos últimos anos, o avanço das tecnologias de inteligência artificial (IA) e, mais especificamente, do aprendizado de máquina (ML), tem gerado grandes expectativas no campo da medicina, incluindo a oftalmologia. Técnicas como as redes neurais convolucionais (CNNs), que pertencem ao ramo do deep learning, têm demonstrado grande potencial para analisar imagens médicas de forma automatizada, identificando padrões complexos que podem ser difíceis de perceber a olho nu. As CNNs têm se mostrado particularmente eficazes na classificação e diagnóstico de condições oftalmológicas, como o glaucoma, a partir de imagens de retina e do nervo óptico. A aplicação dessas tecnologias pode não só agilizar o diagnóstico, mas também torná-lo mais preciso, reproduzível e acessível, uma vez que o processo de análise das imagens pode ser automatizado, superando as limitações associadas à

interpretação subjetiva por parte de profissionais de saúde.

Este estudo tem como objetivo explorar o potencial do aprendizado de máquina para a detecção automatizada do glaucoma, com foco no uso de redes neurais convolucionais (CNNs). Serão avaliados o desempenho e a precisão desses modelos no diagnóstico do glaucoma, além de discutir as limitações e os desafios que ainda precisam ser superados para que essas tecnologias possam ser amplamente adotadas na prática clínica. Além disso, o estudo busca identificar estratégias para melhorar a precisão desses modelos, como a incorporação de novos conjuntos de dados, o ajuste de parâmetros de treinamento e o uso de técnicas de aprimoramento de imagens. Acredita-se que, com o aprimoramento dessas tecnologias, será possível não apenas aumentar a taxa de detecção precoce do glaucoma, mas também reduzir a dependência de métodos tradicionais que podem ser caros e demorados, proporcionando uma alternativa mais acessível, especialmente em regiões com recursos limitados.

Com isso, o trabalho propõe uma análise detalhada da aplicabilidade das redes neurais convolucionais na detecção do glaucoma e investiga as possíveis implicações clínicas e sociais dessa tecnologia, buscando contribuir para um diagnóstico mais eficiente e acessível da doença, com o objetivo final de reduzir os índices de cegueira irreversível causados pelo glaucoma.

III. REVISÃO BIBLIOGRÁFICA

Diversos estudos recentes investigaram a aplicação de aprendizado de máquina em oftalmologia, destacando avanços e desafios no diagnóstico de glaucoma:

Smith et al. (2022): Desenvolveram uma CNN para a detecção de glaucoma em imagens de fundo de olho, alcançando 85 por cento de precisão. O estudo enfatizou o impacto do pré-processamento na qualidade dos resultados, especialmente em bases de dados ruidosas.

Lee et al. (2021): Compararam algoritmos clássicos, como máquinas de vetores de suporte (SVM), com redes profundas. As CNNs superaram algoritmos tradicionais em precisão e robustez, mas o estudo destacou a necessidade de bases de dados mais equilibradas para evitar viés.

Zhao et al. (2023): Propuseram o uso de aprendizado por transferência para lidar com a limitação de bases de dados médicas. A abordagem combinou conhecimento pré-treinado em imagens gerais com ajuste fino para imagens oftalmológicas, alcançando uma melhor generalização.

Martins et al. (2022): Avaliaram o impacto de técnicas de ampliação de dados, como rotações, flips e ajustes de contraste, na robustez de modelos aplicados a imagens médicas, evidenciando uma redução significativa no sobreajuste.

Os estudos também exploraram o uso de aprendizado federado, permitindo o treinamento de modelos em dados distribuídos entre diferentes instituições sem comprometer a privacidade dos pacientes. Essa abordagem se mostra particularmente promissora em aplicações médicas, onde a segurança dos dados é uma preocupação primordial.

IV. MATERIAIS E MÉTODOS

A. Dados

O conjunto de dados utilizado consistiu em 500 imagens retinianas, balanceadas entre as classes "Glaucoma Positivo" e "Glaucoma Negativo". As etapas de pré-processamento incluíram:

Redimensionamento: Todas as imagens foram ajustadas para 224x224 pixels, facilitando sua compatibilidade com arquiteturas padrão de CNNs.

Normalização: Escalonamento dos valores de pixel para o intervalo [0, 1], reduzindo discrepâncias na magnitude dos dados e acelerando a convergência do modelo.

Ampliação de Dados: Foram aplicadas técnicas como rotações aleatórias, flips horizontais, ajustes de brilho e contraste, aumentando a variabilidade do conjunto de treinamento e reduzindo o risco de sobreajuste.

B. Arquitetura do Modelo

O modelo desenvolvido foi baseado em uma arquitetura CNN composta por: Três Camadas Convolucionais: Para extração de características hierárquicas das imagens. Max Pooling: Para redução da dimensionalidade e diminuição da complexidade computacional. Dropout: Com taxa de 0,5 para prevenir o sobreajuste. Camadas Totalmente Conectadas: Para integração das características extraídas e realização da classificação final.

C. Métricas de Avaliação

O desempenho do modelo foi avaliado por meio das seguintes métricas:

Perda de Treinamento e Validação: Monitoramento do aprendizado do modelo ao longo das épocas.

Precisão: Proporção de classificações corretas em relação ao total de amostras.

Matriz de Confusão: Análise detalhada dos erros de classificação, incluindo falsos positivos, falsos negativos, sensibilidade e especificidade.

V. RESULTADOS E DISCUSSÃO

A. Perda e Precisão

Os gráficos de perda de treinamento e precisão mostraram uma redução consistente na perda de treinamento ao longo das épocas, indicando que o modelo estava aprendendo de maneira eficaz a partir dos dados de treinamento. No entanto, foi observado um aumento na perda de validação após a terceira época, o que sugere a ocorrência de sobreajuste (overfitting). Esse padrão é característico quando o modelo começa a se ajustar excessivamente aos dados de treinamento, perdendo sua capacidade de generalizar para novos dados e, assim, afetando a precisão em dados não vistos. Esse comportamento destaca uma possível limitação do modelo, que precisa ser analisada para melhorar sua capacidade de generalização.




Fig. 1. Gráfico de Perda de Treinamento e Validação ao Longo das Épocas




Fig. 2. Evolução da Precisão de Treinamento e Validação ao Longo das Épocas

B. Matrizes de Confusão

A análise inicial da matriz de confusão revelou uma baixa sensibilidade, indicando que o modelo estava identificando um número reduzido de verdadeiros positivos, ou seja, casos de glaucoma corretamente detectados. Esse resultado sugeriu que o modelo não estava sendo eficaz na identificação de pacientes com a doença, o que é crítico em contextos médicos, onde a detecção precoce é fundamental. Após a aplicação de ajustes nos pesos das classes, com o objetivo de aumentar a importância da detecção dos casos positivos, a sensibilidade aumentou significativamente, melhorando a capacidade do modelo em identificar corretamente os casos de glaucoma. No entanto, esse aumento na sensibilidade veio com o compromisso de um maior número de falsos positivos, ou seja, o modelo passou a classificar mais pacientes como positivos para glaucoma, mesmo quando não o eram. Esse ajuste ressaltou a necessidade de equilibrar cuidadosamente os parâmetros do modelo para otimizar a detecção dos casos positivos sem aumentar excessivamente os falsos positivos.




Fig. 3. Matriz de Confusão Inicial Antes do Ajuste dos Pesos das Classes




Fig. 4. Matriz de Confusão Após o Ajuste dos Pesos das Classes

C. Discussão

Os resultados destacam a importância de equilibrar sensibilidade e especificidade nos diagnósticos médicos. A sensibilidade garante que os casos positivos sejam detectados corretamente, enquanto a especificidade evita falsos positivos. Um bom equilíbrio entre essas métricas é crucial, especialmente para condições como o glaucoma, onde o diagnóstico precoce é vital para preservar a visão.

Técnicas como aprendizado por transferência e ampliação de dados podem melhorar o desempenho dos modelos, permitindo que eles aprendam de dados limitados e se adaptem a variações nas imagens. No entanto, é essencial que o modelo seja validado em cenários clínicos reais, para garantir que funcione adequadamente fora do ambiente controlado dos testes e forneça resultados precisos. Sem essa validação, há o risco de decisões incorretas, o que poderia levar a tratamentos inadequados ou até mesmo à omissão de cuidados importantes em contextos clínicos críticos.

VI. CONCLUSÃO

Este estudo demonstrou o grande potencial dos modelos de aprendizado de máquina para a detecção do glaucoma, especialmente quando combinados com técnicas avançadas de regularização e aumento de dados. A regularização ajuda a evitar o sobreajuste, enquanto o aumento de dados melhora a robustez dos modelos, permitindo que eles se adaptem melhor a diferentes variações nas imagens oftalmológicas. No entanto, desafios como o sobreajuste e a falta de grandes bases de dados anotados de forma consistente ainda limitam a aplicação desses modelos em larga escala na prática clínica.

Para avançar, é crucial que os modelos sejam validados em cenários clínicos reais, para garantir que eles funcionem adequadamente fora dos ambientes controlados de pesquisa. Além disso, a integração de dados multimodais, como imagens oftalmológicas, dados clínicos e históricos médicos, pode melhorar ainda mais a precisão do diagnóstico, proporcionando uma abordagem mais completa e personalizada. Focar no desenvolvimento de sistemas robustos que combinem sensibilidade e especificidade será fundamental para garantir diagnósticos confiáveis e eficazes, especialmente em condições críticas como o glaucoma, onde a precisão e o tempo de diagnóstico são essenciais para evitar danos irreversíveis à visão.

VII. REFERÊNCIAS

- Smith, J., et al. (2022). "Deep Learning for Glaucoma Detection," *Journal of Medical Imaging*, 34(2), 123-134.
- Lee, H., et al. (2021). "Comparative Study of Machine Learning Algorithms in Glaucoma Detection," *IEEE Transactions on Biomedical Engineering*, 68(4), 1025-1033.
- Zhao, X., et al. (2023). "Balancing Sensitivity and Specificity in Medical Imaging," *Medical AI Review*, 29(1), 50-61.
- Martins, R., et al. (2022). "Data Augmentation Techniques for Robust Medical Imaging Models," *Conference on Machine Learning in Healthcare*, 87(3), 210-223.